

고등학교 「인공지능 수학」 전체 요약

대한민국 고등학교 인공지능 수학 과정 (총 3단원) 정리 노트

목차

- I. 인공지능과 데이터
- II. 데이터의 분류와 추정
- III. 최적화와 의사결정
- 전체 과정 한눈에

I. 인공지능과 데이터

1. 인공지능과 데이터의 이해

① 인공지능과 수학의 관계

인공지능(AI)이란? 인간의 학습, 추론, 인식, 판단 능력을 컴퓨터로 구현한 기술. 단순 규칙 기반 프로그램과 달리, 데이터로부터 스스로 패턴을 찾아 학습합니다.

왜 수학이 필수인가? AI는 본질적으로 "수학적 모델"입니다. 데이터를 숫자로 표현하고, 숫자 사이의 관계를 함수로 나타내며, 그 함수를 최적화하는 전 과정이 수학으로 이루어집니다.

수학 분야

AI에서의 역할

행렬·벡터 (선형대수)

데이터를 표현하고 변환하는 기본 도구

확률·통계

불확실한 상황에서 추론하고 예측

미분 (해석학)

손실을 줄이는 방향을 찾는 학습 알고리즘

거리·기하

데이터 간 유사성 측정

② 데이터의 유형과 수집

데이터의 유형

형태에 따라:

- 정형 데이터:** 행과 열로 정리된 데이터 (엑셀 표, DB 테이블, CSV)
- 비정형 데이터:** 정해진 구조가 없는 데이터 (텍스트, 이미지, 음성, 영상)

값의 성질에 따라:

- 수치형(양적) 데이터: 키, 몸무게, 온도처럼 숫자로 측정
- 범주형(질적) 데이터: 성별, 혈액형, 지역처럼 분류로 나뉨

데이터 수집 방법

- 1차 데이터: 직접 설문이나 측정으로 수집
- 2차 데이터: 공공데이터포털, 웹 크롤링, API

⚠ 수집 시 개인정보 보호, 저작권, 표본의 편향성을 반드시 고려. 편향된 데이터 → 편향된 AI

2. 데이터의 표현

■ 핵심 메시지: "AI가 이해할 수 있도록 모든 데이터를 숫자로 바꾸자."

① 데이터와 행렬

행렬(Matrix): 데이터를 직사각형 모양으로 배열한 것.

예) 학생 3명의 국·영·수 점수:

$$A = \begin{pmatrix} 90 & 85 & 100 \\ 70 & 95 & 80 \\ 60 & 75 & 90 \end{pmatrix}$$

- 행(row): 한 학생의 데이터 묶음 (관측치, sample)
- 열(column): 같은 종류의 데이터들 (특성, feature)
- 크기: $m \times n$ (m행 n열)

행렬의 기본 연산

- 덧셈/뺄셈: 같은 크기끼리 원소별 계산
- 스칼라곱: 모든 원소에 같은 수를 곱함
- 행렬곱: 데이터 변환에 사용 (AI에서 가장 중요)

② 데이터와 벡터

벡터(Vector): 행렬의 한 행 또는 한 열 (= 숫자들의 한 줄짜리 묶음)

$$\vec{v} = (90, 85, 100)$$

핵심 개념: 데이터 = 공간 속의 점

n개의 특성을 가진 데이터 = n차원 공간의 한 점. 이 관점 덕분에 "데이터가 서로 얼마나 가까운가?"라는 질문을 기하학적 거리 문제로 바꿀 수 있습니다.

벡터의 기본 연산

- 덧셈: $(a_1, a_2) + (b_1, b_2) = (a_1 + b_1, a_2 + b_2)$
- 스칼라곱: $k(a_1, a_2) = (ka_1, ka_2)$
- 크기(노름): $|\vec{v}| = \sqrt{a_1^2 + a_2^2 + \dots} \leftarrow$ 피타고라스 정리의 일반화

③ 텍스트 및 이미지 데이터의 수치화

텍스트의 수치화

- 원-핫 인코딩: 단어 사전이 [사과, 바나나, 포도]일 때
 - 사과 $\rightarrow (1, 0, 0)$
 - 바나나 $\rightarrow (0, 1, 0)$
 - 포도 $\rightarrow (0, 0, 1)$
- 단어 가방(Bag of Words): 문서에서 각 단어가 몇 번 나왔는지
 - "사과 사과 바나나" $\rightarrow (2, 1, 0)$

이미지의 수치화

이미지 = 픽셀들의 격자, 각 픽셀은 밝기값(0~255)

- 흑백 이미지: 가로 w , 세로 $h \rightarrow h \times w$ 행렬
- 컬러 이미지: R, G, B 세 채널 $\rightarrow h \times w \times 3$ 3차원 텐서

예) 28×28 흑백 손글씨 이미지 $\rightarrow$ 784개 숫자 벡터 $\rightarrow$ AI 모델 입력

II. 데이터의 분류와 추정

1. 데이터의 분류

① 규칙 기반 분류와 기계학습 기반 분류

규칙 기반(Rule-based): 사람이 직접 if-else 규칙을 작성

- 장점: 명확하고 설명 가능
- 단점: 복잡한 패턴에선 사람이 규칙 정의 불가능

기계학습 기반(Machine Learning): 데이터를 주면 컴퓨터가 스스로 규칙(패턴) 발견

구분	규칙 기반	기계학습 기반
규칙 작성자	사람	컴퓨터(데이터에서)
데이터 필요량	적음	많음
복잡한 패턴	약함	강함
설명 가능성	높음	낮을 수 있음

② 거리와 유사도

유클리드 거리 (피타고라스 정리의 확장)

2차원: $d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$

n차원으로 일반화:

$$d(\vec{a}, \vec{b}) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2}$$

거리가 가까울수록 유사.

코사인 유사도(Cosine Similarity): 두 벡터의 방향이 얼마나 같은가

$$\cos \theta = \frac{\vec{a} \cdot \vec{b}}{|\vec{a}| |\vec{b}|} = \frac{\sum a_i b_i}{\sqrt{\sum a_i^2} \cdot \sqrt{\sum b_i^2}}$$

- 값의 범위: $-1 \leq \cos \theta \leq 1$
- 1: 방향 같음 (매우 유사)
- 0: 직각 (무관)
- 1: 정반대

언제 어떤 걸 쓸까?

상황	유클리드 거리	코사인 유사도
크기까지 중요할 때 (키, 몸무게)	✓	
방향(비율)만 중요할 때 (단어 비중)		✓
추천 시스템, 텍스트 유사도		✓

③ 속성에 따른 데이터 분류

k-최근접 이웃 (k-NN)

1. 새 데이터와 기존 데이터 거리 모두 계산
2. 가까운 순으로 k개 선택
3. 다수결로 분류 결정

의사결정 트리(Decision Tree): 스무고개처럼 질문을 이어가며 분류. 결과가 if-else 트리 구조라 설명이 쉬움.

2. 경향성과 추정

① 데이터의 시각화와 산점도

산점도(Scatter Plot): 두 변수의 관계를 점으로 시각화

- 우상향 → 양의 관계
- 우하향 → 음의 관계
- 흩어짐 → 관계 없음

② 추세선과 상관관계

상관계수 r ($-1 \leq r \leq 1$)

- $r \approx 1$: 강한 양의 상관
- $r \approx 0$: 상관 없음
- $r \approx -1$: 강한 음의 상관

추세선(회귀선): $y = ax + b$ 형태의 직선으로 데이터를 대표. → 이걸 찾는 게 **선형회귀(Linear Regression)**

⚠ **상관관계 ≠ 인과관계** "아이스크림 판매량 ↑ → 익사 사고 ↑" 는 둘 다 여름 때문이지, 직접 인과관계가 아님.

③ 데이터를 이용한 미래 가치 추정

추세선 $y = ax + b$ 에 새 x 를 대입하여 미래값 예측.

보간 vs 외삽

- 보간(Interpolation): 데이터 범위 **안**에서 예측 → 비교적 신뢰 가능
 - 외삽(Extrapolation): 데이터 범위 **밖**에서 예측 → 위험!
-

III. 최적화와 의사결정

1. 손실함수와 최적화

① 예측 오차와 손실함수

예측 오차: $e_i = y_i - \hat{y}_i$

평균제곱오차 (MSE, Mean Squared Error)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 제곱 → 부호 문제 해결
- 큰 오차에 큰 페널티
- 데이터 개수와 무관

손실함수(Loss Function): 모델이 얼마나 틀렸는지를 나타내는 함수의 통칭. 값이 작을수록 좋은 모델.

② 최적화의 개념

최적화(Optimization): 손실함수를 **최소**로 만드는 파라미터를 찾는 과정.

$$\text{argmin}_{a,b} L(a,b)$$

손실함수 $L(a,b)$ 는 3차원 그릇 모양 곡면. 우리가 찾는 건 **가장 아래 지점**.

③ 경사하강법의 원리

비유: 안개 낀 산에서 발밑 가장 가파른 방향으로 한 걸음씩 내려가기

수학적 표현

$$x_{\text{new}} = x_{\text{old}} - \eta \cdot L'(x_{\text{old}})$$

- η (학습률, learning rate): 한 걸음의 크기
- 기울기 양수 → 왼쪽으로 (값 줄임)
- 기울기 음수 → 오른쪽으로 (값 늘림)
- 기울기 0 → 도착!

학습률 η 의 영향

학습률	결과
너무 작음	수렴 느림
적당함	잘 수렴 ✓
너무 큼	최저점 지나쳐 진동/발산

2. 합리적 의사결정

① 조건부확률과 정보의 수정

조건부확률 $P(A|B)$: 사건 B 가 일어났다는 조건 하에 A 가 일어날 확률.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

핵심 개념: 정보가 들어오면 확률이 갱신된다

- 사전확률(Prior) → [새 증거] → 사후확률(Posterior)

② 베이즈 정리를 활용한 의사결정 모형

베이즈 정리(Bayes' Theorem)

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

- $P(A)$: 사전확률
- $P(B|A)$: 가능도(우도, likelihood)
- $P(B)$: 증거의 확률
- $P(A|B)$: 사후확률

의료 진단 예제

- 인구의 1%가 병에 걸림: $P(\text{병}) = 0.01$
- 검사 정확도 99%: $P(\text{양성}|\text{병}) = 0.99$
- 거짓 양성 5%: $P(\text{양성}|\text{건강}) = 0.05$

질문: 양성 판정을 받았을 때 실제 병일 확률은?

$$P(\text{병}|\text{양성}) = \frac{0.99 \times 0.01}{0.99 \times 0.01 + 0.05 \times 0.99} = \frac{0.0099}{0.0594} \approx 0.167$$

놀라운 결과: 99% 정확한 검사에서 양성이 나와도 실제 병일 확률은 **16.7%뿐!** → 사전확률(병의 희귀성)이 결정적 역할.

③ 인공지능 기반 의사결정의 수학적 탐구

나이브 베이즈 분류기(Naive Bayes Classifier): 베이즈 정리를 분류에 활용한 모델. 대표 응용은 스팸 필터.

스팸 필터 예제

이메일 1000통:


- $P(\text{스팸}) = 0.3$
- $P(\text{당첨}|\text{스팸}) = 0.8$
- $P(\text{당첨}|\text{정상}) = 0.05$

"당첨"이라는 단어가 든 메일이 스팸일 확률은?

$$P(\text{스팸}|\text{당첨}) = \frac{0.8 \times 0.3}{0.8 \times 0.3 + 0.05 \times 0.7} = \frac{0.24}{0.275} \approx 0.873$$


원래 30% → "당첨"이라는 정보 한 개로 **87.3%로 갱신!**

의사결정의 수학적 구조



이 구조는 스팸 필터뿐 아니라 의료 AI 진단, 추천 시스템, 자율주행 인식, 챗봇 응답 선택 등에 모두 적용.

🌐 전체 과정 한눈에



한 줄 정리

Ⅰ단원 (데이터를 숫자로) → Ⅱ단원 (숫자로 분류·예측) → Ⅲ단원 (최적의 모델 찾기 & 확률적 판단)

이 세 단원이 **모든 AI 시스템의 뼈대**입니다. ChatGPT도, 자율주행도, 이미지 생성도, 추천 시스템도 — 표현 방식과 규모는 다르지만 본질은 다음 3단계 위에 서 있습니다:

- 1. 데이터를 벡터/행렬로 표현
- 2. 거리·유사도·추세로 패턴 발견
- 3. 손실함수 최적화 또는 베이지 추론

 핵심 공식 모음

개념	공식
벡터의 크기	$\ \vec{v}\ = \sqrt{a_1^2 + a_2^2 + \dots}$
유클리드 거리	$d = \sqrt{\sum (a_i - b_i)^2}$
코사인 유사도	$\cos \theta = \frac{\vec{a} \cdot \vec{b}}{\ \vec{a}\ \ \vec{b}\ }$
평균제곱오차 (MSE)	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$
경사하강법	$x_{\text{new}} = x_{\text{old}} - \eta \cdot L'(x)$
조건부 확률	$P(A B) = \frac{P(A \cap B)}{P(B)}$
베이지 정리	$P(A B) = \frac{P(B A) \cdot P(A)}{P(B)}$

이 노트는 대한민국 고등학교 「인공지능 수학」 과정의 핵심 개념을 정리한 학습 자료입니다.