

최적화 이론 — 전체 커리큘럼 요약

대한민국 대학교 "최적화 이론" 1~6장 핵심 개념 및 상세 설명 정리

목차

- 1. 일변수 함수의 최대·최소 이론
- 2. 다변수 함수
- 3. 컨벡스 함수
- 4. 제약 조건이 없는 최적화
- 5. 라그랑주 승수법
- 6. 선형대수학

1장. 일변수 함수의 최대·최소 이론

핵심 흐름

미분 → 테일러 급수 → 극값 조건

1장 목표: 함수의 최솟값·최댓값을 어떻게 찾는가?

1.1 일변수 함수 미분

미분은 함수 $f(x)$ 의 순간 변화율. 최적화에서 미분이 중요한 이유:

- $f'(x) = 0$ 인 점이 극값(극대·극소) 후보
- $f''(x)$ 의 부호로 극대/극소 판별

조건	의미
$f'(x_0) = 0$	정류점(Stationary point) — 극값 후보
$f'(x_0) = 0, f''(x_0) > 0$	극소(Local minimum)
$f'(x_0) = 0, f''(x_0) < 0$	극대(Local maximum)
$f'(x_0) = 0, f''(x_0) = 0$	판별 불가 → 고차 도함수 필요

필요조건 vs 충분조건

- 필요조건(1차): $f'(x^*) = 0 \rightarrow$ 극값이면 반드시 성립 (역은 성립 X, 예: $f(x) = x^3$ 의 $x = 0$)
- 충분조건(2차): $f' = 0$ 이고 $f'' > 0$ 이면 극소 확정

1.2 테일러 급수 (Taylor Series)

임의의 (충분히 매끄러운) 함수를 점 a 근방에서 다항식으로 근사:

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x-a)^k + R_n(x)$$

항

역할

$$f(a)$$

함숫값 자체 (0차)

$$f'(a)(x-a)$$

기울기(접선) 정보 (1차)

$$\frac{f''(a)}{2!}(x-a)^2$$

곡률(휨) 정보 (2차)

$$R_n(x)$$

근사 오차 (나머지 항)

최적화에서 활용:

- 1차 근사 $\rightarrow$ Gradient Descent의 이론적 근거
- 2차 근사 $\rightarrow$ Newton법의 이론적 근거 (포물면으로 근사 후 최솟값 해석적 계산)

1.3 Taylor 급수 보충설명 [증명]

나머지 항 $R_n(x)$ — 라그랑주 형태:

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x-a)^{n+1}, \quad \xi \in (a, x)$$

증명 논리 구조:

평균값 정리(MVT) $\rightarrow$ 보조함수 $g(t)$ 정의 $\rightarrow$ 롤의 정리 반복($n+1$ 회) $\rightarrow R_n$ 확정

핵심: 보조함수 $g(t)$ 가 Rolle 정리 조건을 만족 $\rightarrow \xi$ 존재 보장 $\rightarrow$ 라그랑주 형태 유도

수렴 조건: $|f^{(n+1)}|$ 이 유계(bounded)이면 $n \rightarrow \infty$ 일 때 $R_n \rightarrow 0 \rightarrow$ 급수가 실제 함수로 수렴

1장 핵심 요약

개념	수식	최적화 연결
$f'(x^*) = 0$	극값의 필요조건	최솟값 후보 탐색
$f''(x^*) > 0$	극소의 충분조건	최솟값 확정
Taylor 1차 근사	접선으로 함수 대체	Gradient Descent 기반
Taylor 2차 근사	포물면으로 함수 대체	Newton법 기반
나머지 항 R_n	근사 오차의 정량화	알고리즘 수렴 보장

2장. 다변수 함수 (Multi-Variable Functions)

핵심 흐름

1D 개념 → n차원 확장 → 그래디언트·야코비안·헤시안 → Taylor 다변수 → 레벨집합

2장 목표: 1장(1D) 개념을 n차원으로 확장 → 4장 최적화 알고리즘의 직접적 토대

2.1 다변수 함수의 정의

표기	의미	예시
$f: \mathbb{R}^n \rightarrow \mathbb{R}$	n개 입력, 1개 출력 (스칼라)	$f(x, y) = x^2 + y^2$
$f: \mathbb{R}^m \rightarrow \mathbb{R}^n$	m개 입력, n개 출력 (벡터)	로봇 팔 위치 계산

2.2 다변수 함수의 미분

1장의 도함수 $f'(x)$ 가 세 가지 새로운 형태로 확장:

그래디언트 (Gradient) ∇f

- $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 일 때
- $n \times 1$ 열벡터
- 활용: 최급강하 방향 → Gradient Descent

야코비안 (Jacobian) J

- $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$ 일 때
- $n \times m$ 행렬
- 활용: 선형 근사 행렬 $\rightarrow$ 비선형 최소자승

헤시안 (Hessian) H

- 2차 편미분 모음
- $n \times n$ 대칭행렬 ($H_{ij} = H_{ji}$, 슈바르츠 정리)
- 활용: 곡률 정보 $\rightarrow$ **Newton법**

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)^T, \quad H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

2.3 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 의 Taylor 급수

$$f(\mathbf{x}) = f(\mathbf{a}) + \nabla f(\mathbf{a})^T (\mathbf{x} - \mathbf{a}) + \frac{1}{2} (\mathbf{x} - \mathbf{a})^T H(\mathbf{a}) (\mathbf{x} - \mathbf{a}) + \dots$$

1D 용어

nD 대응

$f'(a)$ (스칼라)

$\nabla f(\mathbf{a})$ (벡터)

$f''(a)$ (스칼라)

$H(\mathbf{a})$ (행렬)

$(x - a)^2$ (스칼라 제곱)

$(\mathbf{x} - \mathbf{a})^T H(\mathbf{x} - \mathbf{a})$ (이차형식)

2차 근사까지만 쓰면 $\rightarrow$ 포물면(**paraboloid**) 형태 = Newton법의 핵심 아이디어

2.4 $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$ 의 Taylor 급수

출력도 벡터일 때 1차 근사:

$$f(\mathbf{x}) \approx f(\mathbf{a}) + J(\mathbf{a})(\mathbf{x} - \mathbf{a})$$

1D의 $f'(a)$ 자리에 야코비안 J 가 들어감 $\rightarrow$ **Gauss-Newton법**이 이 선형 근사를 반복 사용

2.5 레벨집합과 그레디언트 방향

레벨집합(Level Set): $L_c = \{\mathbf{x} \mid f(\mathbf{x}) = c\}$ (등고선)

핵심 정리: $\nabla f \perp$ 레벨집합 (항상 성립)

증명 스케치: 레벨집합 위의 경로 $\gamma(t)$ 에 대해 $\frac{d}{dt}f(\gamma(t)) = \nabla f^T \gamma'(t) = 0$
 $\rightarrow \gamma'(t)$ 가 접선벡터이므로 $\nabla f \perp$ 접선

직관:

- ∇f : 함수값이 가장 빠르게 증가하는 방향
- $-\nabla f$: 함수값이 가장 빠르게 감소하는 방향 $\rightarrow$ Gradient Descent의 이동 방향

2장 핵심 요약

개념	수식	모양	4장 연결
그레디언트 ∇f	$n \times 1$ 벡터	방향 벡터	Gradient Descent
야코비안 J	$n \times m$ 행렬	선형 근사	Gauss-Newton
헤시안 H	$n \times n$ 대칭행렬	곡률 정보	Newton법
Taylor 2차 근사	$f(\mathbf{a}) + \nabla f^T \Delta + \frac{1}{2} \Delta^T H \Delta$	포물면	Newton법 정확도
레벨집합	$f(\mathbf{x}) = c$	등고선	제약 최적화(5장)

3장. 컨벡스 함수 (Convex Function)

핵심 흐름

컨벡스 집합 $\rightarrow$ 컨벡스 함수 정의 $\rightarrow$ 판별 조건(1차·2차) $\rightarrow$ 핵심 정리(국소=전역)

3장 핵심: "국소 최솟값 = 전역 최솟값"을 보장하는 조건

3.1 컨벡스 집합 (Convex Set)

집합 $C \subseteq \mathbb{R}^n$ 이 컨벡스:

$\forall \mathbf{x}, \mathbf{y} \in C, \forall \lambda \in [0, 1] : \quad \lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in C$

직관: 집합 안의 임의 두 점을 잇는 선분 전체가 집합 안에 포함

3.1 컨벡스 함수 정의

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}), \quad \forall \mathbf{x}, \mathbf{y}, \lambda \in [0, 1]$$

직관: "두 점 사이의 함수값이 두 점을 잇는 현(chord) 아래에 있다" → 아래로 볼록한 그릇 모양

핵심 정리 모음

정리 1: 1차 조건

$$f \text{ 컨벡스} \iff f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x}), \quad \forall \mathbf{x}, \mathbf{y}$$

직관: 컨벡스 함수는 어느 점에서 그은 접평면보다 항상 위에 있음 (접평면 = 전역 하한)

정리 2: 2차 조건

$$f \text{ 컨벡스} \iff H(\mathbf{x}) \succeq 0 \text{ (양반정치, PSD)}, \quad \forall \mathbf{x}$$

직관: 헤시안 양반정치 → 모든 방향으로 위로 휘어 있음 → 그릇 모양

정리 3: 국소 최솟값 = 전역 최솟값 ★★★

$$f \text{ 컨벡스} \implies \text{국소 최솟값} = \text{전역 최솟값}$$

정리 4: 최적성 조건

$$f \text{ 컨벡스이고 미분 가능} \implies \mathbf{x}^* \text{가 최솟값} \iff \nabla f(\mathbf{x}^*) = 0$$

비컨벡스에서는 $\nabla f = 0$ 이어도 안장점일 수 있지만, 컨벡스에서는 100% 전역 최솟값 확정

정리 5: 컨벡스 함수 연산 보존

연산	결과
비음수 스칼라 곱 αf ($\alpha \geq 0$)	컨벡스
두 컨벡스 함수의 합 $f + g$	컨벡스
컨벡스 함수의 최댓값 $\max(f, g)$	컨벡스
컨벡스 함수의 아핀 합성 $f(Ax + b)$	컨벡스

3장 핵심 요약

정리	내용	의미
정의	$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$	현 조건
1차 조건	$f(y) \geq f(x) + \nabla f(x)^T(y - x)$	접평면이 전역 하한
2차 조건	$H(x) \succeq 0$ (양반정치)	모든 방향 위로 볼록
핵심 정리	국소 최솟값 = 전역 최솟값	알고리즘 수렴 보장
최적성 조건	$\nabla f(x^*) = 0 \iff x^*$ 는 최솟값	필요충분조건

4장. 제약 조건이 없는 최적화

핵심 흐름

기본개념 (하강방향) → GD → Line Search → CG → Newton → LM/Quasi-Newton → 비선형최소자승

- 반복법 공통 구조: $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$

 - $\mathbf{d}_k$: 하강방향 — 어느 방향으로?
 - α_k : 보폭(step size) — 얼마나?

하강방향 조건: $\nabla f(\mathbf{x}_k)^T \mathbf{d}_k < 0$

4.1 기본개념

최적화 알고리즘의 핵심 문제는 두 가지:

- 방향 결정: 어느 방향으로 이동할 것인가?
- 보폭 결정: 얼마나 이동할 것인가?

모든 알고리즘의 차이는 이 두 가지를 어떻게 결정하느냐에 있음

4.2-1 Gradient Descent (경사 하강법)

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \nabla f(\mathbf{x}_k)$$

- 방향: $\mathbf{d}_k = -\nabla f(\mathbf{x}_k)$ (그레디언트 반대 방향)

- **장점:** 구현 단순, H 불필요, 메모리 $O(n)$
- **단점:** 지그재그(zigzag) 경로, 조건수 크면 극도로 느림
- **수렴:** 1차(선형) 수렴

지그재그 원인: 등고선과 직교 방향으로 이동 → 다음 스텝에서 이전 방향 취소 반복

4.2-2 Line Search (직선 탐색)

방향 $\mathbf{d}_k$ 결정 후 보폭 α_k 결정:

방법	설명	특징
정확한 탐색 (Exact)	$\alpha_k = \arg \min_{\alpha} f(\mathbf{x}_k + \alpha \mathbf{d}_k)$	최적이지만 비쌘
Armijo 조건	$f(\mathbf{x}_k + \alpha \mathbf{d}_k) \leq f(\mathbf{x}_k) + c_1 \alpha \nabla f^T \mathbf{d}_k$	충분한 감소 보장
Wolfe 조건	Armijo + 곡률 조건	BFGS 등에서 사용
Backtracking	α 를 $\beta (< 1)$ 씩 줄여 Armijo 만족까지	가장 많이 씀

4.3 Conjugate Gradient (켈레 경사법)

GD의 지그재그를 해결: 이전 방향 정보를 다음 방향에 반영

$$\mathbf{d}_{k+1} = -\nabla f(\mathbf{x}_{k+1}) + \beta_k \mathbf{d}_k$$

β_k 공식	이름
$\frac{\ \nabla f_{k+1}\ ^2}{\ \nabla f_k\ ^2}$	Fletcher-Reeves
$\frac{\nabla f_{k+1}^T (\nabla f_{k+1} - \nabla f_k)}{\ \nabla f_k\ ^2}$	Polak-Ribière

- 이차 함수의 경우 정확히 n 번 만에 수렴 (H 계산 없이!)
- GD보다 훨씬 빠르고 Newton보다 메모리 효율적

4.4-1 Newton법

Taylor 2차 근사를 한 번에 최소화:

$$H(\mathbf{x}_k) \mathbf{d}_k = -\nabla f(\mathbf{x}_k) \implies \mathbf{d}_k = -H^{-1} \nabla f$$

- 수렴: 2차(이차) 수렴 — 오차 $\epsilon \rightarrow \epsilon^2$
- 단점: H 계산 및 역행렬 $O(n^3)$ 비용, H 가 PD가 아닐 때 실패

방법	수렴 차수	H 필요	스텝당 비용
GD	1차 (선형)	불필요	$O(n)$
CG	1~2차	불필요	$O(n)$
Newton	2차 (이차)	필요	$O(n^3)$

4.4-2 Levenberg-Marquardt Damped Newton

Pure Newton의 문제(H 비양정치, 스텝 과도) 해결:

$$(H + \mu I) \mathbf{d}_k = -\nabla f$$

- $\mu \rightarrow 0$: 순수 Newton (빠르지만 불안정)
- $\mu \rightarrow \infty$: GD 방향 (느리지만 안전)
- μ 를 상황에 맞게 조절 $\rightarrow$ 두 방법의 장점 결합

4.4-3 Quasi-Newton (BFGS)

H 를 직접 계산하지 않고 그레디언트 변화로 H 근사 업데이트:

$$B_{k+1} = B_k + \text{rank-2 업데이트}$$

****Secant condition:**** $B_{k+1}(\mathbf{x}_{k+1} - \mathbf{x}_k) = \nabla f_{k+1} - \nabla f_k$

- BFGS가 가장 유명한 구현
- 대규모 문제: L-BFGS (Limited-memory)
- 수렴: 초선형 (1~2차 사이)

4.5 비선형 최소자승법

문제 설정:

$$\min_{\mathbf{x}} F(\mathbf{x}) = \frac{1}{2} \|\mathbf{r}(\mathbf{x})\|^2 = \frac{1}{2} \sum_{i=1}^m r_i(\mathbf{x})^2$$

$\mathbf{r}(\mathbf{x})$: 잔차(residual) 벡터

$$\nabla F = J^T \mathbf{r}, \quad H \approx J^T J \quad (\text{잔차 작을 때})$$

Gauss-Newton:

$$\mathbf{d}_k = -(J^T J)^{-1} J^T \mathbf{r}$$

$J^T J$ 는 항상 PSD $\rightarrow$ 안정적. 잔차 작을 때 Newton에 가까운 수렴 속도

Levenberg-Marquardt (LM):

$$(J^T J + \mu I) \mathbf{d}_k = -J^T \mathbf{r}$$

비선형 최소자승의 최강 실용 알고리즘 — OpenCV 카메라 보정, 번들 조정 등에서 광범위 사용

4장 전체 알고리즘 비교

알고리즘	하강방향 $\mathbf{d}$	수렴속도	H 필요
Gradient Descent	$-\nabla f$	1차 (선형)	불필요
Conjugate GD	$-\nabla f + \beta \cdot \mathbf{d}_{prev}$	1~2차	불필요
Newton	$-H^{-1} \nabla f$	2차 (이차)	필요 $O(n^3)$
Quasi-Newton	$-B^{-1} \nabla f \ (B \approx H)$	초선형	근사 $O(n^2)$
Gauss-Newton / LM	$-(J^T J + \mu I)^{-1} J^T \mathbf{r}$	1~2차	J만 필요

실전 선택:

- 대규모 데이터 $\rightarrow$ **L-BFGS**
- 비선형 피팅 $\rightarrow$ **LM**
- 소규모 정밀 $\rightarrow$ **Newton**

5장. 라그랑주 승수법 (Lagrange Multiplier Method)

핵심 흐름

등호 제약조건 → 라그랑지안 → 안장점 조건 → 부등호 추가 → KKT 4조건

5장 핵심: 제약이 생기는 순간 완전히 새로운 전략 필요

5.1 등호 제약조건

문제 설정:

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{subject to} \quad g_i(\mathbf{x}) = 0, \quad i = 1, \dots, m$$

핵심 직관:

최적점 $\mathbf{x}^*$ 에서 f 의 등고선과 제약 곡선 $g = 0$ 이 접선 공유:

$$\nabla f(\mathbf{x}^*) = \lambda \nabla g(\mathbf{x}^*)$$

평행하지 않다면 → 제약 위를 따라 f 를 더 줄이는 방향 존재 → 최적점이 아님

라그랑지안:

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x})$$

최적 조건 (정류점):

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \nabla f + \lambda \nabla g = 0, \quad \frac{\partial \mathcal{L}}{\partial \lambda} = g(\mathbf{x}) = 0$$

안장점 구조:

$$\mathbf{x}^*, \lambda^* = \arg \min_{\mathbf{x}} \max_{\lambda} \mathcal{L}(\mathbf{x}, \lambda)$$

- $\mathbf{x}$ 에 대해서는 최솟값
- λ 에 대해서는 최댓값

5.2 등호 + 부등호 제약조건 — KKT 조건

문제 설정:

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{s.t.} \quad g_i(\mathbf{x}) = 0, \, i = 1, \dots, m \quad h_j(\mathbf{x}) \leq 0, \, j = 1, \dots, p$$

일반화된 라그랑지안:

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_i \lambda_i g_i(\mathbf{x}) + \sum_j \mu_j h_j(\mathbf{x})$$

KKT 조건 4가지 (최적점의 필요조건):

번호	조건	수식	의미
①	정류점 (Stationarity)	$\nabla f + \sum \lambda_i \nabla g_i + \sum \mu_j \nabla h_j = 0$	이동 불가 방향 없음
②	원시적 가능성 (Primal)	$g_i(\mathbf{x}^*) = 0, \, h_j(\mathbf{x}^*) \leq 0$	$\mathbf{x}^*$ 가 제약 만족
③	이중 가능성 (Dual)	$\mu_j \geq 0$	부등호 승수 비음수
④	상보 여유성 (Complementary)	$\mu_j \cdot h_j(\mathbf{x}^*) = 0$	활성이면 승수, 비활성이면 0

컨벡스 문제에서는 KKT 조건이 필요충분 → 만족하면 전역 최솟값 확정

상보 여유성 직관:

- $h_j(\mathbf{x}^*) < 0$ (내부): 제약 비활성 → $\mu_j = 0$
- $h_j(\mathbf{x}^*) = 0$ (경계): 제약 활성 → $\mu_j \geq 0$

등호 vs 부등호 제약 비교:

	등호 $g = 0$	부등호 $h \leq 0$
승수 부호	λ 임의 (음수 가능)	$\mu \geq 0$ 강제
항상 활성?	항상 활성	활성/비활성 가능
상보 여유성	해당 없음	$\mu \cdot h = 0$

5장 핵심 요약

개념	핵심 수식	직관
라그랑지안	$\mathcal{L} = f + \lambda g + \mu h$	제약을 비용으로 흡수

개념	핵심 수식	직관
등호 최적 조건	$\nabla f = \lambda \nabla g$	두 그래디언트 평행
KKT ① 정류점	$\nabla_{\mathbf{x}} \mathcal{L} = 0$	이동 불가 방향 없음
KKT ② 원시 가능	$g = 0, h \leq 0$	제약 위에 있음
KKT ③ 이중 가능	$\mu \geq 0$	경계 밖으로 못 미는 힘
KKT ④ 상보 여유	$\mu \cdot h = 0$	활성이면 승수, 비활성이면 0

6장. 선형대수학

핵심 흐름

벡터공간 → 부분공간 → 일차결합·독립·기저·차원 → 내적 → 행렬 →
열/행벡터 의미 → 고유치·고유벡터 → Gram-Schmidt → 군론 → $SO(3)$ → $Ax=b$

6장 역할: 최적화의 모든 계산 언어 — 그래디언트(벡터), 헤시안(행렬), Newton 스텝(연립방정식)

6.1 벡터공간 $\mathbb{R}^n$

n 개의 실수 성분 벡터 집합. 덧셈과 스칼라 곱에 대해 8가지 공리(결합법칙, 교환법칙, 영벡터, 역원 등) 만족.

6.2 부분공간 (Subspace)

$W \subseteq \mathbb{R}^n$ 이 부분공간 $\iff$ 덧셈·스칼라 곱에 대해 닫혀(closed) 있음:

- $\mathbf{u}, \mathbf{v} \in W \Rightarrow \mathbf{u} + \mathbf{v} \in W$
- $\alpha \in \mathbb{R}, \mathbf{v} \in W \Rightarrow \alpha \mathbf{v} \in W$
- 반드시 $\mathbf{0} \in W$

대표 예: 행렬 A 의 열공간(column space), 영공간(null space)

6.3 일차결합 — 평행사변형 법칙

$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k$ (스칼라 α_i 로 벡터들을 섞음)

Span: 모든 일차결합의 집합

- $\text{span}\{\mathbf{v}_1\} = \text{직선}$

- $\text{span}\{\mathbf{v}_1, \mathbf{v}_2\}$ = 평면 (비평행 시)
- $\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$ = 공간 (비평면 시)

6.4 일차독립 / 일차종속

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0} \implies \alpha_1 = \dots = \alpha_k = 0$$

이 조건 만족 $\rightarrow$ 일차독립. 아니면 일차종속 (중복 정보 존재).

직관: 일차종속 = "한 벡터가 나머지로 설명 가능" = "중복 정보"

6.5 기저 (Basis) & 차원 (Dimension)

기저 = 일차독립 + 공간 전체 생성(span)

차원 = 기저 벡터의 개수 (기저가 달라도 차원은 유일)

$\mathbb{R}^3$ 표준기저: $\mathbf{e}_1 = (1, 0, 0)^T$, $\mathbf{e}_2 = (0, 1, 0)^T$, $\mathbf{e}_3 = (0, 0, 1)^T$

6.6 내적 (Inner Product)

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^T \mathbf{v} = \sum_{i=1}^n u_i v_i = \|\mathbf{u}\| \|\mathbf{v}\| \cos \theta$$

내적 결과	의미
$= 0$	두 벡터가 직교
> 0	예각 방향
< 0	둔각 방향
$\mathbf{v}^T \mathbf{v} = \ \mathbf{v}\ ^2$	벡터 길이 제곱

4장 GD의 "하강방향 조건 $\nabla f^T \mathbf{d} < 0$ "이 내적이 음수인 것

6.7 행렬 (Matrices)

$A \in \mathbb{R}^{m \times n}$ 은 선형 변환 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 을 나타냄

- 열공간 (Col A): A의 열벡터 span $\rightarrow$ 도달 가능한 출력

- 영공간 (Null A): $A\mathbf{x} = \mathbf{0}$ 의 해 전체 $\rightarrow$ 변환 후 사라지는 방향
- Rank-Nullity 정리: $\text{rank}(A) + \text{nullity}(A) = n$

6.8 & 6.9 벡터공간·행렬의 관계 / 열벡터·행벡터 의미

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \cdots + x_n\mathbf{a}_n$$

열벡터 관점: $A\mathbf{x}$ 는 A의 열벡터들을 $\mathbf{x}$ 성분으로 섞는 일차결합
 $\rightarrow A\mathbf{x} = \mathbf{b}$ 가 해를 가지려면 $\mathbf{b} \in \text{Col}(A)$

6.10 고유치 & 고유벡터 — 기하학적 의미

$$A\mathbf{v} = \lambda\mathbf{v}$$

$\mathbf{v}$ 는 방향이 바뀌지 않고 크기만 λ 배. 특성방정식 $\det(A - \lambda I) = 0$ 으로 고유치 계산.

λ 값	변환 효과
$\lambda > 1$	같은 방향으로 늘어남
$0 < \lambda < 1$	같은 방향으로 줄어듦
$\lambda < 0$	반전 후 스케일
$\lambda = 0$	영공간으로 붕괴

최적화 연결: 헤시안의 고유치가 모두 양수 $\iff$ 양정치(PD) $\iff$ 극솟값

6.11 Gram-Schmidt 직교화

기저 $\{\mathbf{v}_1, \dots, \mathbf{v}_n\} \rightarrow$ 직교기저 $\{\mathbf{u}_1, \dots, \mathbf{u}_n\}$:

$$\mathbf{u}_1 = \mathbf{v}_1$$

$$\mathbf{u}_k = \mathbf{v}_k - \sum_{j=1}^{k-1} \frac{\langle \mathbf{v}_k, \mathbf{u}_j \rangle}{\langle \mathbf{u}_j, \mathbf{u}_j \rangle} \mathbf{u}_j$$

각 단계에서 이전 벡터들에 대한 정사영(projection)을 빼서 직교 성분만 남김
 $\rightarrow$ 정규화하면 정규직교기저(ONB)

6.12 군론 (Group Theory) 정의

집합 G 와 이항연산 $\cdot$ 이 군 $\iff$ 4공리 만족:

공리	내용
닫힘 (Closure)	$a, b \in G \Rightarrow a \cdot b \in G$
결합법칙 (Associativity)	$(a \cdot b) \cdot c = a \cdot (b \cdot c)$
항등원 (Identity)	$\exists e : e \cdot a = a \cdot e = a$
역원 (Inverse)	$\forall a, \exists a^{-1} : a \cdot a^{-1} = e$

6.13 & 6.14 직교행렬과 $SO(3)$ — 3차원 회전

$$R^T R = I, \quad \det(R) = +1 \implies R \in SO(3)$$

$SO(3)$ 의 군 성질:

- 닫힘: $R_1 R_2 \in SO(3)$
- 항등원: I_3
- 역원: $R^{-1} = R^T$
- 비가환군: $R_1 R_2 \neq R_2 R_1$ (일반적으로)

응용: 로봇 팔 자세, 카메라 외부 파라미터, 3D 물체 변환, SLAM·번들 조정

z 축 기준 회전행렬 예:

$$R_z(\theta) = \begin{pmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

6.15 선형방정식의 해: $A\mathbf{x} = \mathbf{b}$

경우	조건	해
유일한 해	$\text{rank}(A) = n = m$ (정방·가역)	$\mathbf{x} = A^{-1}\mathbf{b}$

경우	조건	해
해 없음	$\mathbf{b} \notin \text{Col}(A)$	최소자승해 사용
무한히 많은 해	$\text{rank}(A) < n$ (영공간 존재)	특수해 + 영공간
최소자승해	$m > n$ (과결정계)	$\mathbf{x} = (A^T A)^{-1} A^T \mathbf{b}$

최소자승해 $(A^T A)^{-1} A^T \mathbf{b} = \mathbf{4.5}$ 절 선형 최소자승법의 해
비선형 버전 = Gauss-Newton법

6장 핵심 요약

개념	핵심	최적화 연결
벡터공간·부분공간	닫힘 조건	해공간 구조 파악
기저·차원	독립 + 생성	자유도 = 차원
내적	$\mathbf{u}^T \mathbf{v} = \ \mathbf{u}\ \ \mathbf{v}\ \cos \theta$	하강방향 조건
행렬	선형변환 $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$	야코비안·헤시안
고유치·고유벡터	$A\mathbf{v} = \lambda\mathbf{v}$	헤시안 PD 판별
Gram-Schmidt	정사영 빼기 반복	QR 분해·CG법
SO(3)	$R^T R = I, \det = 1$	회전 최적화
$A\mathbf{x} = \mathbf{b}$	$\mathbf{b} \in \text{Col}(A)$ 이어야 해 존재	Newton·GN 스텝

전체 커리큘럼 연결 지도

- 1장 (1D 미분·Taylor)
 ↓ n차원 확장
- 2장 (다변수 함수: ∇f , J, H, Taylor, 레벨집합)
 ↓ 볼록성 조건
- 3장 (컨벡스 함수: 국소=전역 보장)
 ↓ 알고리즘으로
- 4장 (무제약 최적화: GD → CG → Newton → LM → 비선형최소자승)
 ↓ 제약 추가
- 5장 (라그랑주·KKT: 등호·부등호 제약)

↑ 계산 도구

6장 (선형대수: 벡터공간·행렬·고유치· $SO(3)$ · $Ax=b$)

생성일: 2025년 | 최적화 이론 1~6장 전체 요약